

## ● Exercises

이번 Exercise에선 coin toss 상황에서 다른 prior(uniform, gaussian, beta) distribution에 대해 MAP가 어떻게 변하는지 scipy 라이브러리를 이용하여 구현하는 게 목표이다. MAP에 대한 설명 이전에 1), 2)는 MLE에 대한 내용이다.

### 1) Implement likelihood

Likelihood란, observed data에 대해 주어진 data를 가장 잘 표현하는 parameter를 구하는 방법 중 하나로, observed data가 어떤 확률분포에서 나왔는가에 대응되는 값이다. Coin toss의 경우,  $x=1$ (head)가 나올 확률  $p$ ,  $x=0$ (tail)이 나올 확률  $1-p$ 를 가지므로, Bernoulli distribution을 따른다고 볼 수 있으며 단일 시행에 대해  $L(x_i|p) = p^{x_i}(1-p)^{1-x_i}$  ( $x_i = 0,1$ )의 likelihood를 가진다.  $n$ 회의 coin toss를 시행 시, likelihood는  $L(x|p) = \prod_i L(x_i|p) = \prod_i p^{x_i}(1-p)^{1-x_i} = p^x(1-p)^{n-x}$  ( $x$ : head 횟수)로 나타낼 수 있다. 이에 대한 code는 [Fig 1]과 같다.

```
def likelihood(x, n, p):
    ##### implement here #####
    return (p**x)*((1-p)**(n-x))
    #####
```

[Fig 1] Code for Exercise 1 ( $x$ : head,  $n$ : total toss,  $p$ : probability 1d array)

**Explanation:** code 그대로  $p^x(1-p)^{n-x}$ 를 반환한다. (\*  $p$ 는  $[0,1]$  내 동일 간격의 10001개 values에 대한 np.ndarray이다)

### 2) Implement calculate\_MLE

1)에서 구한 likelihood 함수에 np.ndarray type의 parameter  $p$ 를 input에 넣으면, 각 element에 대한 likelihood를 계산 및 np.ndarray type으로 return한다. 그 중, 가장 큰(maximum) 값을 가진  $p$ 를 추출하는 함수이며, 그  $p$ 가 likelihood를 maximize하는 parameter이라 이 과정을 MLE(Maximum Likelihood Estimation)라 부른다. 해당  $p$ 가 해당 observed data가 가장 잘 나오는 경우에 대응되는 것이다. 이에 대한 code는 [Fig 2]와 같다.

```
def calculate_MLE(x, n, p):
    ##### implement here #####
    L = likelihood(x,n,p)
    return p[np.argmax(L)]
    #####
    ## print(calculate_MLE(50, 100, p))
```

[Fig 2] Code for Exercise 2 ( $x$ : head,  $n$ : total toss,  $p$ : probability 1d array)

**Explanation:** 변수  $L$ 이 1)에서 구한 likelihood 함수의 np.ndarray type 1D output이다. np.argmax는 input ndarray 중 가장 큰 값을 가지는 element의 index를 반환한다. 구하고자 하는 것은 그 maximum 상황에서의 parameter  $p$  값이므로,  $p$  배열에서 np.argmax에 해당하는 index의 element를 return하면 끝나므로, 'return p[np.argmax(L)]'로 정리할 수 있다.

Posterior란, data를 관찰한 후 그 data가 특정 model에서 발생했을 확률이며 사전 확률(prior probability)이 uniform하지 않은 경우에 대해 보정이 적용된 것이 사후 확률 posterior probability이다. 다시 말해, 위 MLE는  $p$ 에 대한 분포(prior)를 고려하지 않은 경우이고 MAP와 이점이 크게 다르다. 앞서 말한 prior에 대한 code가 [Fig 3]과 같다. mode parameter에는 uniform, beta, gaussian이 들어갈 수 있으며, uniform인 경우가 MAP와 MLE가 같은 경우에 대응된다. Beta distribution과 gaussian distribution의 경우,  $p$  배열을 input으로 받아, param\_1, param\_2의 parameter로  $p$  배열에 대한 prior를 적용한다. 이 때, beta의 경우  $Beta(p; \alpha, \beta)$ 에서  $\alpha, \beta$ 가, gaussian인 경우  $N(p; \mu, \sigma^2)$ 에서  $\mu, \sigma$ 가 param\_1, param\_2에 해당한다.

```
def prior(p, mode, param_1, param_2):
    if mode == 'uniform':
        return 1.0 # Uniform prior
    elif mode == 'beta':
        return beta.pdf(p, param_1, param_2) # Beta prior
    elif mode == 'Gaussian':
        return norm.pdf(p, param_1, param_2) # Gaussian prior
```

[Fig 3] prior function (includes uniform, beta, gaussian distribution)

### 3) Implement unnormalized\_posterior

Posterior는 data를 observed하였다는 사후 조건의 개념이므로, Bayes' theorem에 따라  $p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$ 로 계산할 수 있다 (이 Summary에서는,  $\theta$ 는 1D array  $p$ 의 원소들에 해당한다). 이 때,  $p(x|\theta)$ 는 위에서 구한 likelihood  $L(x|\theta)$ 에 대응되는 비례 관계의 항이며,  $p(x)$ 는 parameter  $\theta$ 와 무관한 항이므로, 따라  $p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)} \propto L(x|\theta)p(\theta)$ 라는

비례 관계가 성립한다. 여기서  $L(x|\theta)p(x)$  는 unnormalized posterior(integral 시 1 이 되지 않은 unnormalized 상태이면서 posterior 와 비례한 식) 라 부를 수 있다.

**Explanation:** [Fig 4]에 implement 되어 있는 앞선 설명에 따라 unnormalized\_posterior 함수는 1)에서의 likelihood(x,n,p)와 [Fig 3]의 prior(p,mode,param\_1,param\_2)의 곱으로 표현할 수 있다. 단순히 해당 값을 return 하면 되며, 총 6 개의 parameters 들을 받는다.

#### 4) Implement calculate\_MAP

3)에서 구현한 unnormalized\_posterior 은 인자로 받은 p array 각각의 elements 에 대한  $L(x|\theta)p(x)$  값으로 구성된 1D array 를 output 으로 반환한다. 그 1D array 내 가장 큰 unnormalized\_posterior 값을 만들어내는 parameter p 를 MAP 라 한다. 즉, MLE 와 똑같이 np.argmax 함수를 이용하여 maximizer p 를 p array 내에서 찾아내면 된다. Code 진행은 [Fig 5]와 같다.

**Explanation:** unnormalized\_posterior 의 maximizer p 를 구하는 것이므로, 2)와 code flow 는 동일하다.

## ● Discussion

### 1) Fair coin tosses in small number / large number

10 회의 coin toss 에 대해 fair coin(양면 모두  $p_{\text{real}}=0.5$ ) 특정 seed(random 한 상황을 부여하는 난수)를 주고 MLE 와 각기 다른 prior 들을 가진 MAP 들을 비교해볼 것이며, coin 을 10 회가 아닌 100 회를 던졌을 때와는 어떤 차이를 보이는 지

분석하고자 한다. 해당 discussion 에서 seed 는 head 가 3 회 나온 경우가 조성되도록 값이 지정되었다.

MLE 는 logarithm likelihood  $\ln L(x|p) = x \ln p + (n-x) \ln(1-p)$ 를 p 에 대해 미분하여 maximizer p 를 구하며,  $\frac{d}{dp}(\ln L) = \frac{x}{p} - \frac{n-x}{1-p} = 0, p = \frac{x}{n}$ 가 analytic method 로 구한 \*maximizer 이다. 실제로, 2)에서 구한 calculate\_MLE 함수를 이용하면, [Fig 6-1]과 같이  $p=0.3$  의 MLE 가 도출되었음을 알 수 있다.

이번엔 MAP 계산을 위해 [Fig 6-2] 와 같은 bell-shaped 모양의 Gaussian( $N(0.5, 0.05^2)$ ), Beta( $Beta(20,20)$ ) 분포, 그리고 Uniform( $U(0,1)$ )의 prior 을 사용하며, MAP 와 MLE 를 비교하겠다. Uniform prior 의 경우, 앞서 설명한대로 MLE 와 MAP 에 따른 p 값이 동일한 0.3 의 값으로 나오며, 다른 prior 의 경우 [Fig 7]과 같은 모습을 보인다(설명에 앞서, 해석의 편의성을 위해 graph 들의 y 값에 대해 normalization 이 적용되었음을 알린다). 0.3 이라는 동일한 maximizer p 의 파란색 likelihood 와는 거리가 많이 먼 posterior(핑크색) 분포를 보이고 있으며, MAP 값은 beta 의 경우 약 0.4583, gaussian 의 경우 0.4818 의 MLE=0.3 과는 다른 값을 가진다([Fig 7]의 하늘색 점선 참고).


두 Beta 분포의 곱(합성)은 다른 Beta 분포를 도출한다는 성질에 따라, 여기서 likelihood  $L(x|p) = p^x(1-p)^{n-x} \propto Beta(x+1, n-x+1)$  또한 일종의 beta 함수 형태를 가지므로, prior 가 beta 분포인 경우엔 posterior 도 beta 분포를 된다. [Fig 7]의 upper graph 에서 파란색 likelihood 와 초록색 prior 의 곱이 분홍색 posterior 을 만드는 것이며, 그래서 posterior graph 가 likelihood 와

```
def unnormalized_posterior(x, n, p, mode, param_1, param_2):
    ##### implement here #####
    return likelihood(x,n,p)*prior(p, mode, param_1, param_2)
    #####
```

[Fig 4] Code for Exercise 3 (meaning of the same parameter names by likelihood & prior function)

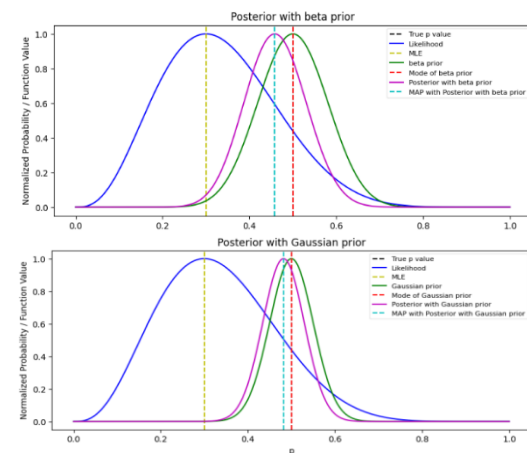
```
def calculate_MAP(x, n, p, mode, param_1, param_2):
    ##### implement here #####
    return p[np.argmax(unnormalized_posterior(x,n,p,mode,param_1,param_2))]
    #####
```

[Fig 5] Code for Exercise 4 (same parameters as unnormalized posterior function)



[Fig 6-1] (Left) Likelihood(blue) and MLE(red dot)

[Fig 6-2] (Right) Gaussian(red) and Beta(blue) distribution



[Fig 7] Posterior(pink), Likelihood(blue) Graph with beta (upper) and gaussian (lower) prior distribution (n=10, x=3)

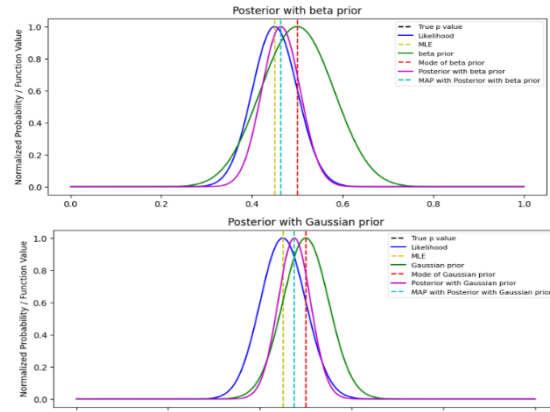
prior graph 사이에 형성되며 MAP 는 MLE 인 0.3 과, prior 중심인 0.5 사이에 형성된 것이다. Gaussian 의 경우 exact 한 분포를 구할 순 없지만, likelihood graph 와 prior graph 의 곱이 unnormalized posterior( $L(x|\theta)p(x)$ )임은 동일하므로, 그 둘 사이의 posterior graph 를 얻었다고 유추할 수 있고, beta prior 인 경우보다 더 sharp 한 prior 를 gaussian prior 에서 갖기 때문에, posterior 가 likelihood 보다 prior 쪽에 더 가깝게 위치, 즉 MAP 의 값 측면에서 gaussian 인 경우가 beta 인 경우보다 더 크게 나온 사실과 부합한다.

n (#coin toss)값을 10 에서 100 으로 늘린 경우, [Fig 8]의 result 를 얻을 수 있다. [Fig 8]의 결과는 100 번의 fair coin toss 중 head 가 45 번 나온 경우를 바탕으로 나온 결과임에 유의하자. MLE 는 0.45 가 나오며, n 이 커지면서 likelihood graph 가  $p=0.45$  를 중심으로 narrow 해졌음을 알 수 있고, 그렇기 때문에 이전과 동일한 prior 을 곱하면, [Fig 7]과 같은 맥락으로 봉우리가 있는 posterior 을 얻을 수 있다. MAP 는 beta 에선 0.4638, gaussian 에선 0.475 이 나왔다. 추가로, MLE 의 변화량이 MAP 보다 더 dramatic 함을 확인할 수 있으며, n 이 더 커진다면, MLE 는 실제 coin 의 확률( $p_{\text{real}}$ )인 0.5 에 근접해질 것이고, MAP 또한 0.5 에 같이 근접해짐을 알 수 있다.

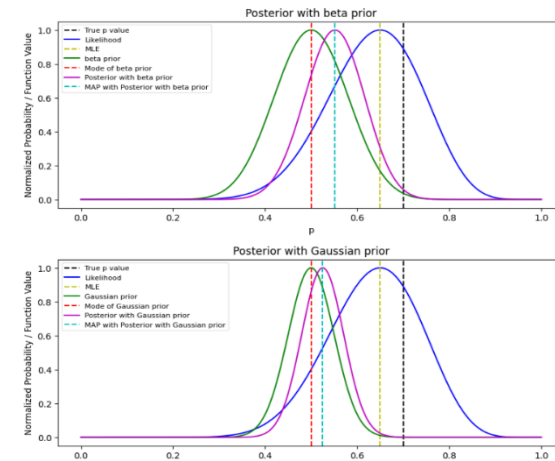
## 2) Unfair coin tosses in medium number / large number with prior correction

이번엔  $p_{\text{real}}=0.7$  인 경우에 대해 observed data 가 coin toss  $n=20$ , head  $x=13$  인 경우 결과는 어떠할 지 확인해보고자 한다. 현재 prior 의 parameter 는 1)과 똑같이 Gaussian( $N(0.5, 0.05^2)$ ), Beta( $Beta(20, 20)$ ) 이다. 결과는 [Fig 9]와 같으며, MAP 의 경우 beta 에선 0.5517, gaussian 에선 0.5251 이 나왔다.


$p_{\text{real}}$  인 0.7(검은색 점선)과 MAP(하늘색 점선)의 위치가 두 경우 모두 크게 다른 것을 알 수 있는데, prior 의 parameter 설정이 잘못되었음을 알 수 있다. Beta 분포에서 현재  $n=20$ ,  $x=13$  이므로  $Beta(x+1=14, n-x+1=8)$ 를 가지며 Beta 분포에서 mode 란 maximum 이 생기는  $p$  를 의미하며, 앞서 말한 MLE 와 동일한 개념이다. Mode 의 값 또한 MLE 와 동등한 derivation 및 value 인  $p = \frac{x}{n}$  을 가지며, 여기서 prior\_mode 값을  $\frac{13}{20} = 0.65$  로 바꿔(correction)줘야 한다.



[Fig 8] Resulting graph in large number of coin toss ( $n=100$ ,  $x=45$ ) (same labels as [Fig 7])



[Fig 9] Resulting graph in unfair coin toss case ( $p_{\text{real}}=0.7$ ,  $n=20$ ,  $x=13$ ) (same labels as [Fig 7])



[Fig 10] Resulting graph in unfair coin toss case ( $p_{\text{real}}=0.7$ ,  $n=100$ ,  $x=74$ ) (same labels as [Fig 7])

(left) : beta prior without correction ( $Beta(20, 20)$ ), (middle) gaussian prior ( $N(0.5, 0.05^2)$ ), (right) beta prior with correction ( $Beta(14, 8)$ ),

해당 correction 을 적용한 상태에서 n 을 20 에서 100 으로 늘리면서 head x 가 74 인 상황( $p_{\text{real}}$  은 0.7 그대로)을 관찰했을 때, MLE=0.74 이며 posterior 계산 시 [Fig 10]과 같은 결과를 얻을 수 있다. Correction 이 적용된 beta prior 을 보면  $p=0.5$  를 기준으로 symmetric 했던 분포가 이제는  $p=0.65$  에서 maxima 를 가지는 오른쪽으로 쏠린 beta prior(초록색) 분포를 보인다. 우편향된 prior 와 역시 우편향된 likelihood 의 중첩으로, posterior 역시 다른 case 들과 다르게  $p=0.7 \sim 0.8$  부근에 봉우리를 자리잡고 있다. [Fig 10]에서 순서대로 MAP 는 0.6739, 0.6238, 0.725 가 나왔으며, correction 이 적용된 beta prior 의 posterior case 가 가장  $p_{\text{real}}$  에 근접한 model 임을 결론 지을 수 있다.